

# V Big Data and Machine Learning Bootcamp

## Data Processing

### PRACTICA (2/3)

#### Punto 1.2 (CON KAFKA)

- Nos desplazamos al directorio donde se encuentran los ejecutables de Kafka

```
$ cd /usr/local/Cellar/kafka/2.4.0/bin
```

- Lanzamos el servidor de zookeeper

```
$ sudo zookeeper-server-start /usr/local/etc/kafka/zookeeper.properties
```

- A continuación, lanzamos el servidor de kafka

```
$ sudo kafka-server-start /usr/local/etc/kafka/server.properties
```




Foto 1. Comandos antes de ejecutarse\*

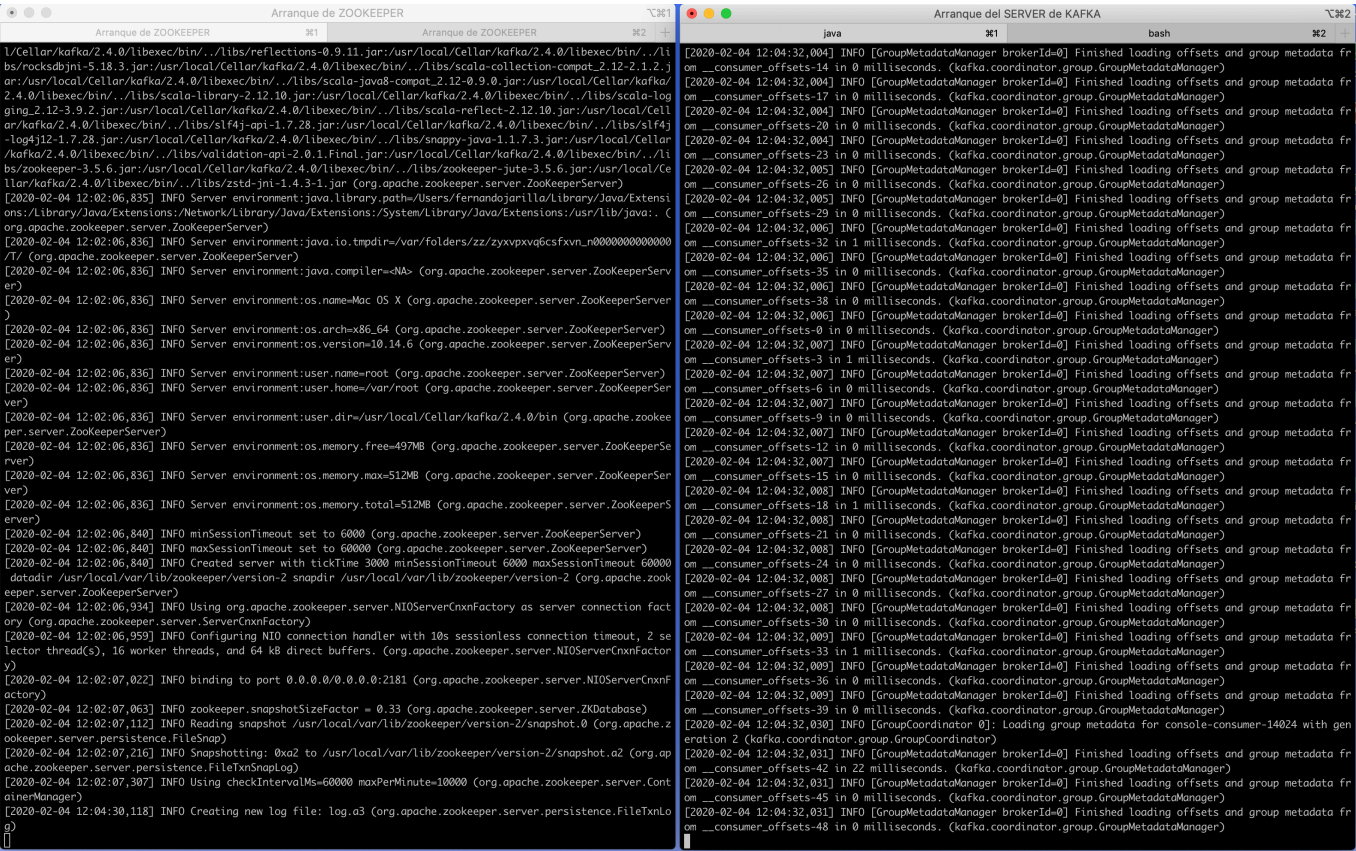


Foto 2. Comandos de arranque se servers ejecutados

- Una vez lanzados los servers, haré uso del tópico creado en el punto anterior que llamé **practica**

- A continuación, crearé el **PRODUCTOR**

```
$ sudo kafka-console-producer --broker-list localhost:9092 --topic practica
```

- Una vez todo preparado, el comando a ejecutar para que el productor envíe el fichero que queremos leer será:

```
$ cat /users/fernandojarilla/Desktop/personal.json | sudo kafka-console-producer --broker-list localhost:9092 --topic practica
```

- Con todo el entorno listo, nos vamos al IDE de IntelliJ y dentro del proyecto donde hemos hecho el curso (en mi caso **EjerciciosMaster**), creamos una nueva **ScalaClass** como **Object** que llamaremos **KafkaConsumer**
- El programa generado es el siguiente:

```

//Realizar la conexión
val spark:SparkSession = SparkSession.builder()
    .master( master = "local[2]")
    .appName( name = "KafkaConsumer")
    .getOrCreate()

//Crear el DStream
val df = spark.readStream
    //Formato de datos
    .format( source = "kafka")
    //Puerto de conexión
    .option("kafka.bootstrap.servers", "localhost:9092")
    //Topic al que se subscribe))
    .option("subscribe", "practica")
    //Comenzar a leer desde el principio
    .option("startingOffsets", "earliest")
    .load()

//Casteamos los datos leídos en formato Kafka, para convertirlos en strings
val res = df.selectExpr( exprs = "CAST(value AS STRING)")

//Creamos el esquema (Fichero personal.json)
val esquema = new StructType()
    .add( name = "id", IntegerType)
    .add( name = "first_name", StringType)
    .add( name = "last_name", StringType)
    .add( name = "email", StringType)
    .add( name = "gender", StringType)
    .add( name = "ip_address", StringType)

//Hacemos una consulta que nos devuelva la información (Tengo un DataStream)
val persona = res.select(from_json(col( colName = "value"), esquema)
    .as ( alias = "data")) //Importamos functions
    .select( col = "data.*")

//Visualizamos la información recibida
persona.writeStream
    .format( source = "console")
    .outputMode( outputMode = "append")
    .option("truncate", false)
    .start()

//Hacemos una consulta que nos filtre los registros
val personaFiltrado = persona
    .filter( conditionExpr = "data.last_name != 'Bea'")
    .filter( conditionExpr = "data.first_name != 'Giavani'")

//Visualizamos
personaFiltrado.writeStream
    .format( source = "console")
    .outputMode( outputMode = "append")
    .option("truncate", false)
    .start()
    .awaitTermination()
  
```

Foto 3: Aplicación con Streaming - Kafka

- Una vez ejecutada la aplicación y lanzado el productor, recogemos los resultados.

```
20/02/09 21:03:08 INFO ContextCleaner: Cleaned accumulator 25
20/02/09 21:03:08 INFO ContextCleaner: Cleaned accumulator 58
20/02/09 21:03:08 INFO ContextCleaner: Cleaned accumulator 49
20/02/09 21:03:08 INFO ContextCleaner: Cleaned accumulator 79
20/02/09 21:03:08 INFO ContextCleaner: Cleaned accumulator 81

+-----+
|id|first_name|last_name|email|gender|ip_address|
+-----+
|1|Jeanette|Penddreth|jpenddreth0@census.gov|Female|26.58.193.2|
|2|Giavani|Frediani|gfrediani1@senate.gov|Male|229.179.4.212|
|3|Noell|Bea|nbea2@imageshack.us|Female|180.66.162.255|
|4|Willard|Valek|wvalek3@vk.com|Male|67.76.188.26|
+-----+

20/02/09 21:03:08 INFO BlockManagerInfo: Removed broadcast_2_piece0 on 192.168.0.14:52992 in memory (size: 6.4 KB, free: 4.1 GB)
20/02/09 21:03:08 INFO DataWritingSparkTask: Commit authorized for partition 0 (task 3, attempt 0, stage 3.0)
20/02/09 21:03:08 INFO ContextCleaner: Cleaned accumulator 68
20/02/09 21:03:08 INFO DataWritingSparkTask: Committed partition 0 (task 3, attempt 0, stage 3.0)
20/02/09 21:03:08 INFO ContextCleaner: Cleaned accumulator 82
```

Foto 4: Fichero .json recibido

```
+-----+
|id|first_name|last_name|email|gender|ip_address|
+-----+
|1|Jeanette|Penddreth|jpenddreth0@census.gov|Female|26.58.193.2|
|4|Willard|Valek|wvalek3@vk.com|Male|67.76.188.26|
+-----+

20/02/09 21:06:48 INFO WriteToDataSourceV2Exec: Data source writer org.apache.spark.sql.execution.streaming.sources.MicroBatchWriter@348cd7c1
20/02/09 21:06:48 INFO CheckpointFileManager: Writing atomically to file:/private/var/folders/mg/dtnr15yj2wz0_p1kkskg3lfw0000gn/T/temporary-7
20/02/09 21:06:48 INFO SparkContext: Starting job: start at KafkaConsumer.scala:61
20/02/09 21:06:48 INFO DAGScheduler: Job 7 finished: start at KafkaConsumer.scala:61, took 0,000028 s
20/02/09 21:06:48 INFO CheckpointFileManager: Writing atomically to file:/private/var/folders/mg/dtnr15yj2wz0_p1kkskg3lfw0000gn/T/temporary-6
20/02/09 21:06:48 INFO CheckpointFileManager: Renamed temp file file:/private/var/folders/mg/dtnr15yj2wz0_p1kkskg3lfw0000gn/T/temporary-7d342
20/02/09 21:06:48 INFO MicroBatchExecution: Streaming query made progress: {
  "id" : "bbec2de3-270b-49b5-9f42-95c780189cb3",
  "runId" : "e2415598-e4d7-4cea-8fc0-6c2590d2894f",
  "name" : null,
  "timestamp" : "2020-02-09T20:06:48.087Z",
```

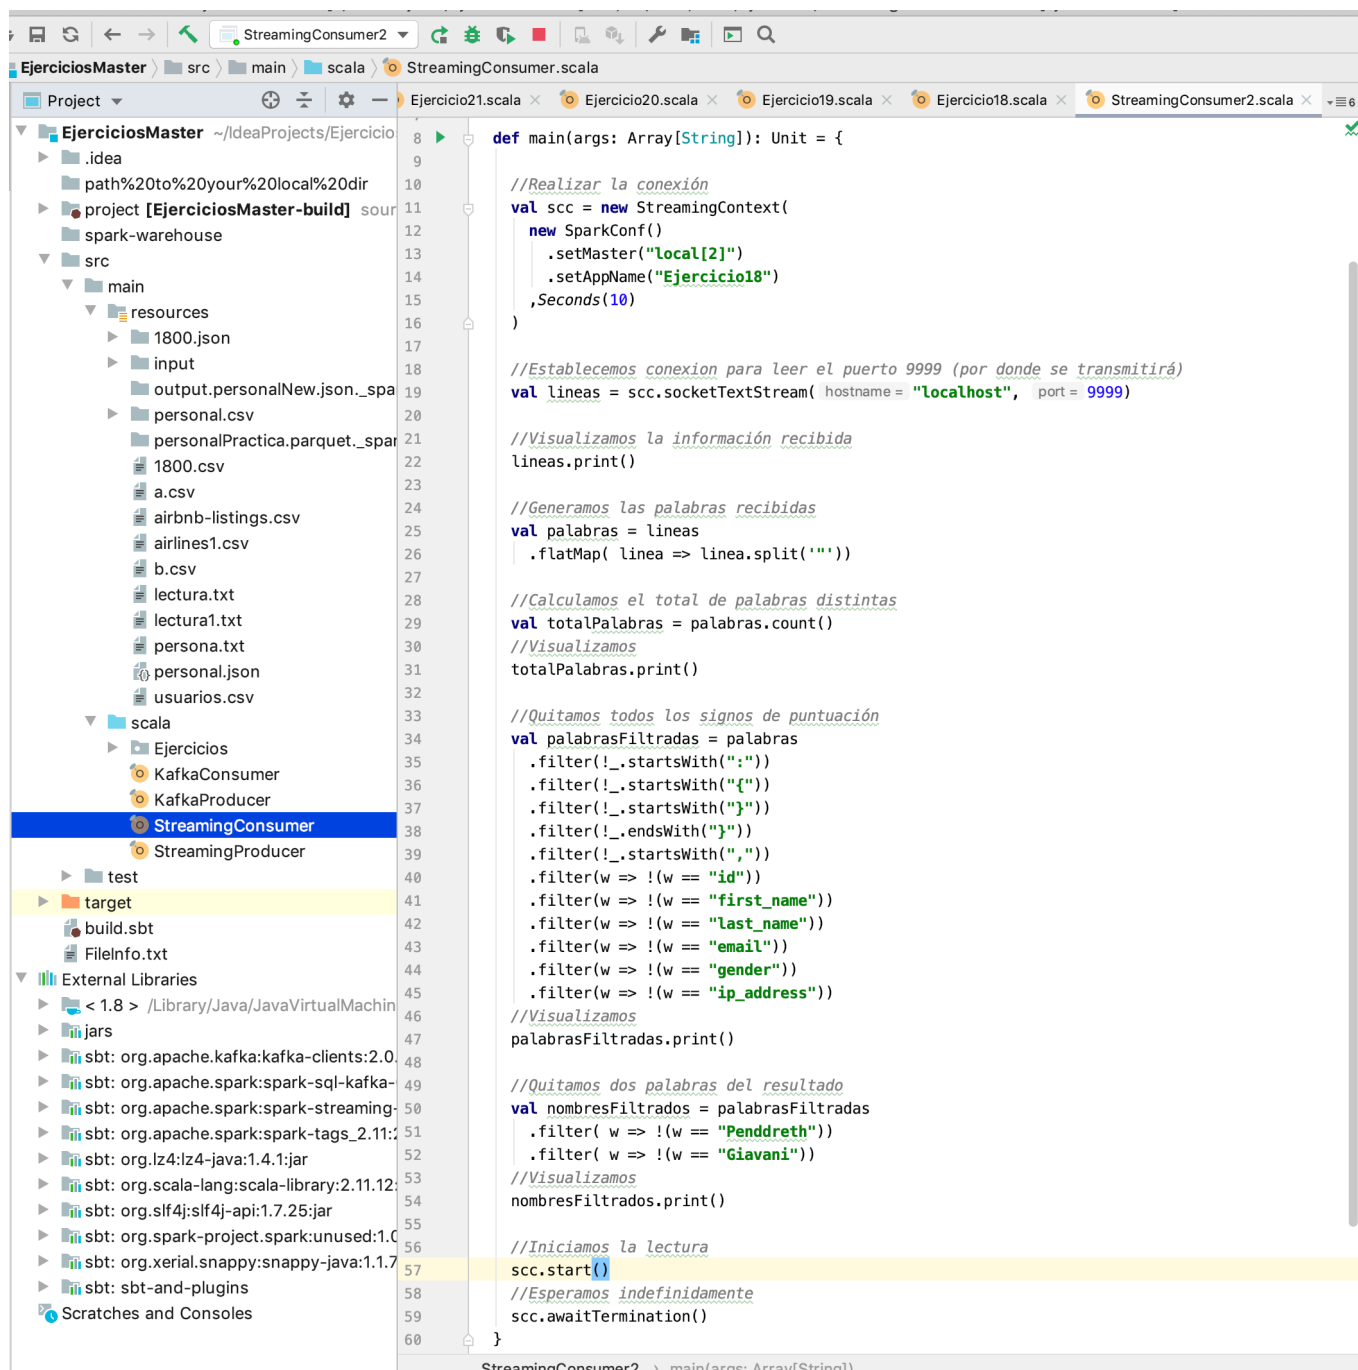
Foto 5: Datos una vez filtrados

## Punto 1.2 (CON STREAMING)

- Generamos el comando a enviar como productor.

```
iMac:Desktop fernandojarilla$ cat personal.json | nc -l 9999
```

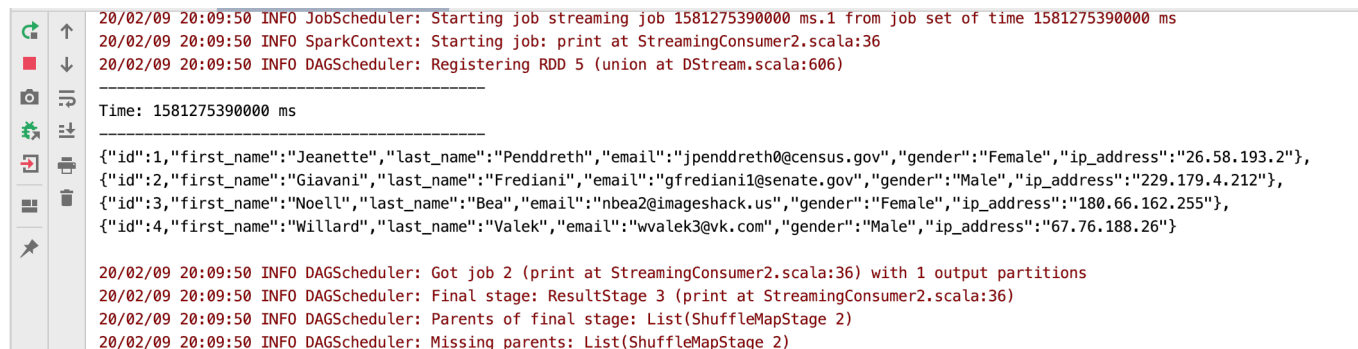
- Lanzamos la aplicación que es la siguiente y hemos generado con el IDE de IntelliJ de forma similar al punto anterior.



```
def main(args: Array[String]): Unit = {  
    //Realizar la conexión  
    val scc = new StreamingContext(  
        new SparkConf()  
            .setMaster("local[2]")  
            .setAppName("Ejercicio18")  
            ,Seconds(10)  
    )  
  
    //Establecemos conexión para leer el puerto 9999 (por donde se transmitirá)  
    val lineas = scc.socketTextStream( hostname = "localhost", port = 9999)  
  
    //Visualizamos la información recibida  
    lineas.print()  
  
    //Generamos las palabras recibidas  
    val palabras = lineas  
        .flatMap( linea => linea.split(''))  
  
    //Calculamos el total de palabras distintas  
    val totalPalabras = palabras.count()  
    //Visualizamos  
    totalPalabras.print()  
  
    //Quitamos todos los signos de puntuación  
    val palabrasFiltradas = palabras  
        .filter(!_.startsWith(":"))  
        .filter(!_.startsWith("("))  
        .filter(!_.startsWith("}"))  
        .filter(!_.endsWith("("))  
        .filter(!_.startsWith(","))  
        .filter(w => !(w == "id"))  
        .filter(w => !(w == "first_name"))  
        .filter(w => !(w == "last_name"))  
        .filter(w => !(w == "email"))  
        .filter(w => !(w == "gender"))  
        .filter(w => !(w == "ip_address"))  
  
    //Visualizamos  
    palabrasFiltradas.print()  
  
    //Quitamos dos palabras del resultado  
    val nombresFiltrados = palabrasFiltradas  
        .filter( w => !(w == "Penddredth"))  
        .filter( w => !(w == "Giavani"))  
  
    //Visualizamos  
    nombresFiltrados.print()  
  
    //Iniciamos la lectura  
    scc.start()  
    //Esperamos indefinidamente  
    scc.awaitTermination()  
}
```

Foto 1: Programa fuente

- Tras la ejecución los resultados son:



```
20/02/09 20:09:50 INFO JobScheduler: Starting job streaming job 1581275390000 ms.1 from job set of time 1581275390000 ms  
20/02/09 20:09:50 INFO SparkContext: Starting job: print at StreamingConsumer2.scala:36  
20/02/09 20:09:50 INFO DAGScheduler: Registering RDD 5 (union at DStream.scala:606)  
  
-----  
Time: 1581275390000 ms  
-----  
{ "id":1, "first_name": "Jeanette", "last_name": "Penddredth", "email": "jpennredth@census.gov", "gender": "Female", "ip_address": "26.58.193.2" },  
{ "id":2, "first_name": "Giavani", "last_name": "Frediani", "email": "gfrediani@senate.gov", "gender": "Male", "ip_address": "229.179.4.212" },  
{ "id":3, "first_name": "Bea", "last_name": "Noell", "email": "nbea2@imageshack.us", "gender": "Female", "ip_address": "180.66.162.255" },  
{ "id":4, "first_name": "Willard", "last_name": "Valek", "email": "wvlek3@vk.com", "gender": "Male", "ip_address": "67.76.188.26" }  
  
20/02/09 20:09:50 INFO DAGScheduler: Got job 2 (print at StreamingConsumer2.scala:36) with 1 output partitions  
20/02/09 20:09:50 INFO DAGScheduler: Final stage: ResultStage 3 (print at StreamingConsumer2.scala:36)  
20/02/09 20:09:50 INFO DAGScheduler: Parents of final stage: List(ShuffleMapStage 2)  
20/02/09 20:09:50 INFO DAGScheduler: Missing parents: List(ShuffleMapStage 2)
```

Foto 2: Fichero .json recibido por streaming

